

Практическая работа №5

Trade-off и метрики релиза

Цель работы: научиться принимать решения о приоритетах (trade-off переговоры), исходя из метрик, ресурсов и неожиданных событий. Связать качество релиза с бизнес-эффективностью.

Матрица приоритетов с учётом непредвиденных факторов

Релиз 7: Внедрение AI-ассистент для автоматической категоризации и тегирования документов

Во время релиза возникли следующие "черные лебеди": Внешний AI-сервис резко поднял цены в день релиза, а также юридический отдел потребовал вести лог всех AI-решений для аудита.

Высокие затраты	Логирование AI-решений Ограничение частоты запросов	AI-категоризация Кэширование результатов AI Fallback на локальную модель
Низкие затраты		Расширенный набор категорий (30 типов) Автоматическое обучение модели Голосовая категоризация
	Низкие усилия	Высокие усилия

Таблица метрик релиза (TCO, CPU, ROI, Run vs Grow и др.)

Метрика	Плановое значение	Фактическое значение
TCO(Total Cost of Ownership)	4 936 000 руб.	4 936 000 руб.
CPU(Cost per Unit)	14.9 руб. (один запрос)	53,08 руб.(после увеличения на 0,5\$)
ROI(Return on Investment)	11,1%	6,1%
Run vs Grow Ratio	25%/75%	40%/60%

Анализ влияния рисков и итоговый план корректировок

Негативные последствия

- Рентабельность релиза просела почти в два раза
- Рост операционных затрат увеличивает срок окупаемости
- Задержки из-за новых требований (логирование)
- Рост нагрузки на инфраструктуру
- Появление зависимости от внешнего поставщика.

Положительные сигналы

- Требования юридического отдела увеличивают доверие клиентов, следовательно повышают долгосрочный ROI
- Локальная модель и кэширование снижают будущие риски
- Проект становится более устойчивым и масштабируемым

Итоговый план корректировок

Срочные корректировки:

1. Внедрить кэширование AI-результатов

- Снижение CPU минимум на 30–60%
- Быстрая реализация (1–2 дня)

2. Ввести rate limiting

- Снижение TCO при росте цен
- Уменьшение нагрузки на API

3. Реализовать логирование AI-решений

- JSON-лог
- Хранение 90 дней.

Среднесрочные корректировки

4. Построить Fallback-модель

- Снижение зависимости от внешнего SaaS
- Использовать при превышении лимитов/авариях

5. Оптимизировать затраты:

- переход на пачки запросов
- выбор более дешёвого тарифа AI

Функции, которые следует перенести

6. Расширенный набор категорий (30 типов) - перенос на следующий квартал.

7. Автоматическое обучение модели - высокие затраты, низкий ROI сейчас

8. Голосовая категоризация - заморозить до стабилизации Run-cost